Popularidad histórica de canciones

Informe individual de modelamiento, evaluación y traspaso al equipo

Lucas Moncada
Evaluación Parcial 2 - Machine Learning

24 de octubre de 2026

Este informe consolida el trabajo de Lucas y entrega a Ignacio y César las decisiones, cifras, figuras y límites que deben poder reproducir y explicar. La evidencia ejecutable es `notebooks/04a_modeling_lucas.ipynb`; el informe no sustituye al notebook integrador ni al README Markdown exigido para la entrega del equipo.

Resumen

Se estudió si atributos musicales y géneros permiten estimar la popularidad histórica de 89.740 canciones únicas de Spotify Tracks. Ridge completo obtuvo MAE 11,915, RMSE 16,643 y $R^2 = 0,348$ en la prueba aleatoria, frente a MAE 17,250 de la referencia mediana. Quitar los géneros elevó el MAE de Ridge a 16,671. Una prueba separada por artista principal mantuvo MAE 12,102, con artistas secundarios compartidos en parte de la prueba. El ranking del 10 % recuperó 159 de 653 canciones populares y omitió 494. K-Means produjo dos perfiles musicales amplios cuya separación es modesta (silueta 0,245). Los hallazgos sirven para formular auditorías de catálogo; no establecen causalidad ni anticipan el éxito futuro.

Índice

1. Propósito y mapa de evidencias **2**

2. Metodología, fuente y preparación **2**

2.1. Partición común y prevención de fuga 2

3. Aprendizaje supervisado **4**

3.1. Aporte de los géneros 4

4. Transferencia a artistas principales no vistos **5**

5. Errores extremos y ranking retrospectivo **5**

6. Perfiles no supervisados de canciones **7**

6.1. Estabilidad de los perfiles 8

7. Conclusiones y uso compartido **8**

7.1. Traspaso a Ignacio y César 9

1. Propósito y mapa de evidencias

La pregunta supervisada es cuánto aportan el audio y los géneros a la estimación de `popularity`, un valor histórico entre 0 y 100. La pregunta no supervisada es si los atributos musicales permiten describir perfiles útiles para explorar el catálogo. El KPI retrospectivo simula una capacidad de revisión del 10 % de la prueba y cuenta cuántas canciones con `popularity >= 70` aparecen en esa lista. El valor real ya existe en la fuente: el ejercicio no representa una decisión comercial lista para usar.

Artefacto	Uso para Ignacio, César y el notebook integrador
`docs/ea2/protocolo_comun.md`	Definiciones compartidas de datos, particiones, modelos y métricas.
`notebooks/04a_modeling_lucas.ipynb`	Cálculo reproducible, salidas, figuras e interpretación del trabajo de Lucas.
`src/spotify_popularity/modeling/protocol.py`	Funciones de partición, codificación, pipelines y métricas.
`docs/ea2/lucas.md`	Alcance individual y reproducción desde instalación limpia.
Este informe	Síntesis para revisión cruzada; las cifras oficiales del equipo se recalculan en el notebook 05.

Cuadro 1: Función de cada artefacto en el traspaso.

2. Metodología, fuente y preparación

El trabajo sigue CRISP-DM de manera verificable: pregunta y KPI para la *comprensión del negocio*; controles de la fuente y hallazgos de EP1 para la *comprensión de datos*; deduplicación y codificación para la *preparación*; Ridge, árbol y K-Means para *modelamiento*; pruebas, segmentos, ranking y sensibilidades para *evaluación*; notebook e informe para la entrega académica, sin despliegue operativo. La evaluación retroalimenta la definición de uso: los errores extremos impiden recomendar decisiones automáticas.

La fuente inmutable es `data/raw/Spotify_Tracks_Dataset.csv`, con SHA-256:

`b202fa49909b2d5cef71a04b1d21243cfeb36414535f2ca9272aa646721177bd`

De 114.000 filas se retiró una inválida y se consolidaron 24.259 repeticiones de `track_id`; el procesado tiene 89.740 canciones únicas, 20 columnas y cero faltantes. La popularidad queda en 0–100. EP1 encontró 10,47 % de ceros, 3,48 % de canciones con popularidad al menos 70 y asociaciones acústicas individuales débiles. La fuente aportaba exactamente 1.000 filas por género antes de consolidar duplicados; sus frecuencias no representan el catálogo natural.

2.1. Partición común y prevención de fuga

Se ordenaron los `track_id` únicos y se aplicó `train_test_split` con `test_size=0.20`, semilla 42 y mezcla aleatoria. Quedaron 71.792 canciones de entrenamiento y 17.948 de prueba. Del entrenamiento se apartó un 20 % adicional: 57.433 para ajustar candidatos y 14.359 para validarlos. La huella SHA-256 de los IDs ordenados de la prueba aleatoria es:

`7270ff57b6fb81215fba2f834942d194183e3854ccac935a65e5a03f7888b318`

Los tres integrantes deben usar esos mismos IDs para la comparación principal.

El objetivo, `track_id`, nombres, álbum y artistas no entraron como predictores. Las diez columnas numéricas fueron `duration_ms`, `danceability`, `energy`, `loudness`, `speechiness`, `acousticness`,

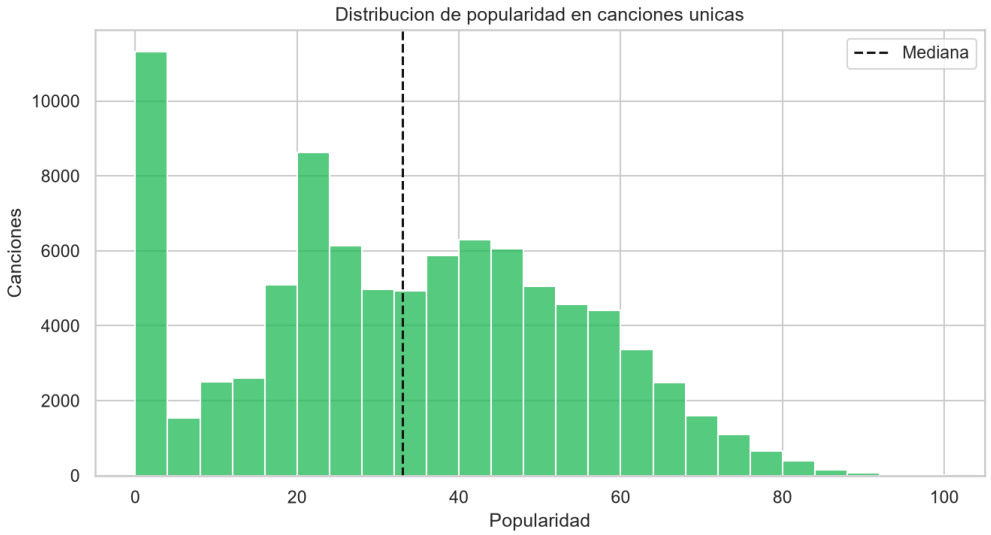


Figura 1: Distribución de popularidad del procesado, proveniente del EDA de EP1. Los extremos justifican la referencia mediana y el diagnóstico por rangos.

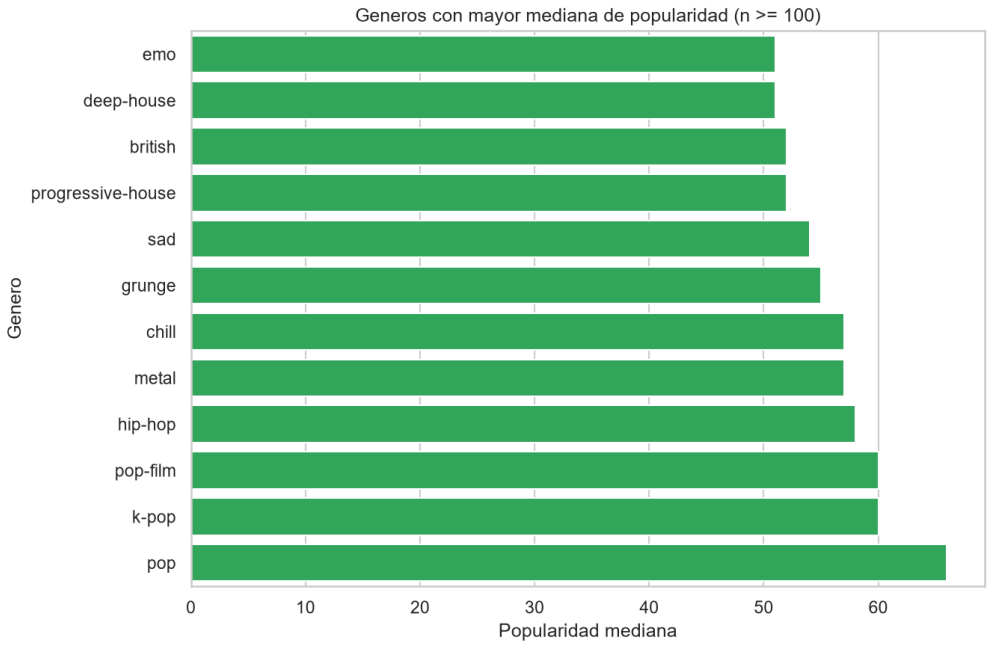


Figura 2: Resumen descriptivo por género elaborado en EP1. Su lectura está condicionada por el diseño de muestreo.

`instrumentalness`, `liveness`, `valence` y `tempo`. Las cuatro categóricas fueron `key`, `mode`, `time_signature` y `explicit`. `track_genres` se separó por `|` y se codificó como multietiqueta. Escalado, one-hot y codificación de géneros se ajustaron dentro de cada pipeline usando solo la partición de entrenamiento correspondiente; las etiquetas no vistas se ignoran.

3. Aprendizaje supervisado

`popularity` es numérica, por lo que se compararon regresores. Una referencia `DummyRegressor` con estrategia mediana fija el MAE que deben superar. Ridge ofrece una combinación lineal regularizada ante atributos correlacionados; el árbol de regresión captura umbrales e interacciones, con riesgo de sobreajuste. Se probaron `alpha` 0,1; 1; 10 y 100 para Ridge, y profundidades 5, 10 o 15 con hojas mínimas de 20 o 100 para el árbol. La regla fue menor MAE de validación, luego RMSE y menor complejidad. No se usó la prueba para elegir parámetros.

Predictores	Modelo	MAE	RMSE	R^2	Configuración
Completo	Ridge	11,786	16,430	0,360	$\alpha = 0,1$
Completo	Árbol	14,393	18,312	0,205	prof. 15; hoja 20
Sin géneros	Ridge	16,581	20,162	0,036	$\alpha = 0,1$
Sin géneros	Árbol	15,627	19,830	0,067	prof. 15; hoja 20

Cuadro 2: Configuraciones seleccionadas en validación aleatoria; la referencia tuvo MAE 17,208.

Tras reajustar cada configuración con las 71.792 canciones de entrenamiento, Ridge completo obtuvo el menor MAE de la prueba aleatoria, como muestra la Tabla 3. MAE y RMSE se expresan en puntos de popularidad. R^2 compara el error cuadrático con una predicción constante igual a la media observada de la prueba.

Predictores	Modelo	MAE	RMSE	R^2	Mejora MAE
Referencia	Mediana	17,250	20,612	≈ 0	0,000
Completo	Ridge	11,915	16,643	0,348	5,335
Completo	Árbol	14,508	18,460	0,198	2,742
Sin géneros	Ridge	16,671	20,223	0,037	0,580
Sin géneros	Árbol	15,693	19,834	0,074	1,557

Cuadro 3: Prueba aleatoria reservada, $n = 17.948$. La mejora MAE se calcula frente a la referencia mediana de esta misma prueba.

3.1. Aporte de los géneros

La ablación principal retira solo `track_genres` y conserva audio, estructura musical y `explicit`. Bajo esa única diferencia, el MAE de Ridge aumenta 4,756 puntos (11,915 a 16,671) y el del árbol aumenta 1,186 (14,508 a 15,693). En una comparación adicional *solo de validación* se aislaron exactamente las diez variables numéricas de audio, las etiquetas de género y ambas juntas; las cuatro categóricas quedaron fuera para que los nombres de los conjuntos fueran literales. Los mismos IDs y la misma regla de selección se usaron en cada variante.

Con Ridge, añadir audio a solo géneros reduce el MAE de validación apenas 0,049 puntos. La señal de género sostiene casi todo el rendimiento de esa combinación en esta muestra. No se puede cuantificar qué parte persistiría con una distribución natural de géneros ni atribuir causalidad al género.

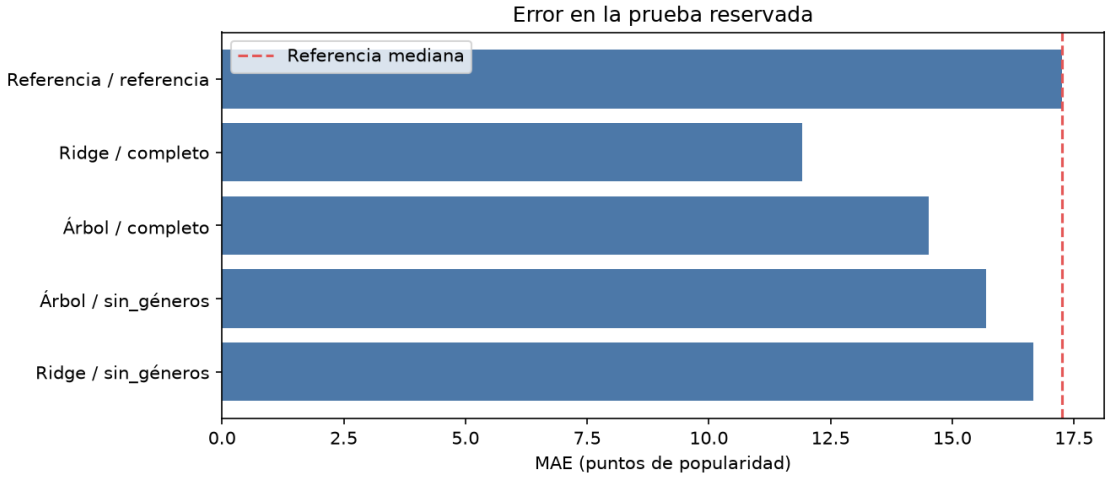


Figura 3: MAE de las configuraciones preseleccionadas en la prueba aleatoria. La línea vertical corresponde a la referencia mediana.

Variables	MAE Ridge	R^2 Ridge	MAE árbol	R^2 árbol
Solo audio	16,630	0,032	15,686	0,092
Solo géneros	11,849	0,355	14,472	0,204
Audio y géneros	11,800	0,358	14,391	0,204

Cuadro 4: Análisis adicional en los mismos 14.359 IDs de validación; no reabre la prueba aleatoria.

4. Transferencia a artistas principales no vistos

Como diagnóstico secundario se definió el grupo por el primer nombre de `artists` antes de `;`, sin espacios laterales y sin distinguir mayúsculas. `GroupShuffleSplit` con semilla 42 reservó 18.193 canciones de 3.528 artistas principales para prueba y 71.547 canciones de 14.111 artistas principales para entrenamiento. Dentro de este último se separaron 57.176 para ajuste y 14.371 para validación agrupada. La selección de parámetros se repitió allí desde cero, sin usar la validación aleatoria. La huella SHA-256 de los IDs de prueba agrupada es:

`a76b54b8e2fd914db9dc5984ff77a8ac07e5b13bf0f36b7e371d048194e5ac52`

No hay artistas *principales* compartidos entre entrenamiento y prueba. Sí hay 1.732 nombres que figuran como artistas secundarios en canciones de prueba y aparecen en entrenamiento en algún rol; 2.633 canciones de prueba contienen al menos uno. Este diagnóstico no equivale a una prueba con todos los colaboradores nuevos. El 20 % de `GroupShuffleSplit` se refiere a grupos, por lo que no exige un 20 % exacto de canciones.

Ridge completo mantuvo una mejora frente a su referencia (27,6 % en MAE, frente a 30,9 % en la partición aleatoria). Los MAE 12,102 y 11,915 no corresponden a las mismas canciones; su diferencia no mide por sí sola el efecto causal de excluir artistas ya vistos. La popularidad es histórica y la muestra conserva el sesgo por género.

5. Errores extremos y ranking retrospectivo

El MAE global de Ridge completo oculta extremos difíciles. En las 653 canciones con popularidad real al menos 70, el MAE fue 36,759 y la mediana predicha 40,035; todas recibieron una predicción menor que 70. En las 1.863 canciones de popularidad cero, el MAE fue 24,448 y la mediana predicha

Predictores	Modelo	MAE	RMSE	R^2	Mejora MAE
Referencia	Mediana	16,707	20,075	$-0,003$	0,000
Completo	Ridge	12,102	16,740	0,302	4,605
Completo	Árbol	14,455	18,247	0,171	2,252
Sin géneros	Ridge	16,245	19,855	0,019	0,462
Sin géneros	Árbol	15,703	19,652	0,039	1,004
Solo géneros	Ridge	12,120	16,763	0,301	4,587
Solo géneros	Árbol	14,500	18,268	0,169	2,207

Cuadro 5: Prueba por artista principal, $n = 18.193$. Cada variante eligió parámetros dentro de la partición agrupada.

23,369. Hubo 651 errores absolutos de al menos 40 puntos: 236 fueron canciones de popularidad al menos 70 y 278 tuvieron popularidad cero. El rango predicho fue aproximadamente $-31,636$ a 79,706; 76 predicciones quedaron bajo cero porque Ridge no restringe su salida a 0–100. Se conservaron esos valores para el diagnóstico, sin ajustar una corrección al mirar la prueba.

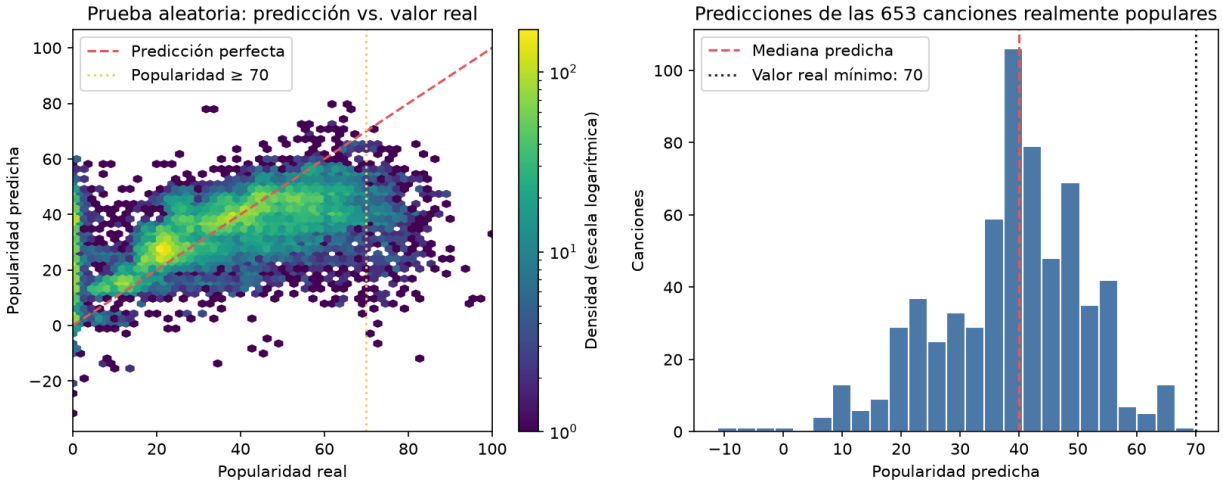


Figura 4: Valor predicho frente al real y distribución de predicciones de las 653 canciones realmente populares. La concentración intermedia explica subestimaciones grandes en el extremo alto.

El modelo no contiene identidad de artista, fecha ni exposición promocional. Esa ausencia es una explicación plausible de su dificultad para distinguir un éxito excepcional o un cero entre canciones de géneros y perfiles parecidos, pero los datos no permiten asignar una causa individual a cada error. El MAE fue 14,198 en canciones `explicit=True` ($n = 1.517$) y 11,704 en `explicit=False` ($n = 16.431$); los soportes son distintos y la diferencia no demuestra un efecto de la explicitud.

El KPI utiliza una capacidad prefijada de 1.795 canciones (10 % redondeado hacia arriba), popularidad real al menos 70 y desempate por `track_id`. Precisión es la proporción de populares dentro de la lista; recall es la proporción recuperada de las 653 populares de la prueba; lift divide la precisión por la prevalencia de 3,64 % en *esta muestra*.

Al incluir géneros, Ridge recupera 23 populares adicionales respecto a la variante sin géneros, y el árbol 37. El ranking de Ridge completo supera una selección aleatoria de igual tamaño en esta muestra, pero deja fuera 494 de las 653 populares y selecciona 1.636 que no alcanzan el umbral. El lift no acredita utilidad comercial: la fuente ya contiene popularidad histórica y el modelo falla en los extremos absolutos.

Ranking del 10 %	Populares halladas	Precisión	Recall	Lift
Referencia mediana	63	3,5 %	9,6 %	0,965
Ridge completo	159	8,9 %	24,3 %	2,435
Ridge sin géneros	136	7,6 %	20,8 %	2,082
Árbol completo	119	6,6 %	18,2 %	1,822
Árbol sin géneros	82	4,6 %	12,6 %	1,256

Cuadro 6: Ranking retrospectivo de las variantes declaradas. Porcentajes redondeados.

6. Perfiles no supervisados de canciones

K-Means responde una pregunta distinta a la regresión: ¿aparecen perfiles musicales reconocibles al agrupar canciones por sus atributos de audio? Se usaron las 71.792 canciones del entrenamiento aleatorio, sin popularidad, géneros, identificadores ni nombres en la matriz. Las diez variables numéricas declaradas en la sección anterior se estandarizaron; los centroides se ajustaron en esa escala. Para reducir la dependencia de una inicialización particular se fijó semilla 42 y `n_init=10`. Se comparó $K = 2, \ldots, 8$ mediante inercia y silueta estimada sobre 2.000 observaciones de entrenamiento.

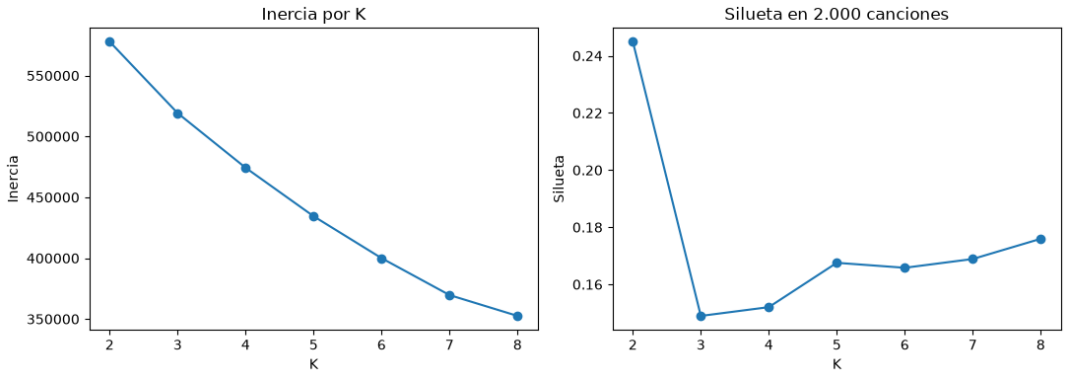


Figura 5: Inercia y silueta para $K = 2, \ldots, 8$. La curva apoya una solución descriptiva de dos grupos; la silueta máxima usada es 0,245. Figura extraída de la salida ejecutada del notebook 04a.

Se eligió $K = 2$ por el balance entre lectura e indicador, con silueta 0,245. Este valor indica separación limitada, no dos clases naturales de canciones. Los perfiles se describieron con estadísticas en unidades originales y la popularidad se consultó *después* de agrupar, únicamente como descriptor.

Grupo	Canciones	Energía	Acústica	Loudness	Bailabilidad	Popularidad mediana
0	54.011	0,762	0,078	$-6,140$	0,607	34
1	17.781	0,295	0,828	$-13,033$	0,468	29

Cuadro 7: Perfil del entrenamiento. Los valores acústicos son medianas descriptivas en escala original. La popularidad no intervino en K-Means.

El grupo 0 reúne principalmente canciones más enérgicas, menos acústicas y con mayor `loudness`; el grupo 1, canciones más acústicas y suaves. La mediana de popularidad difiere cinco puntos, sin que esta comparación pruebe que pertenecer a un grupo cause mayor popularidad. PCA se utilizó solo para proyectar la matriz estandarizada en dos ejes: ambos explican conjuntamente 44,1 % de la varianza, por lo que la figura omite más de la mitad de la información.

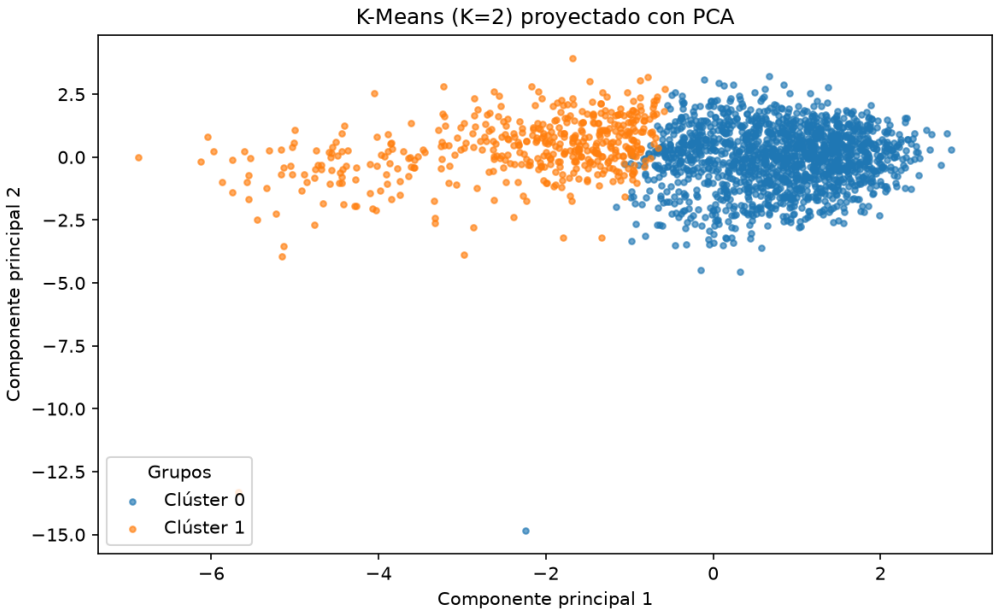


Figura 6: Proyección PCA de los dos grupos de K-Means. El solapamiento visible concuerda con la silueta moderada; la proyección no es evidencia de separación perfecta en diez dimensiones.

6.1. Estabilidad de los perfiles

Se repitió $K = 2$ con el mismo entrenamiento y la misma semilla bajo dos cambios aislados: transformar `duration_ms` con $\log(1 + x)$ antes de escalar, y retirar `loudness`. Los números de grupo son arbitrarios; la concordancia se calculó después de alinear las etiquetas. ARI compara particiones sin depender de esos nombres.

Configuración	Silueta	ARI vs. base	Coincidencia	Tamaños
Base, diez atributos	0,245	1,000	100,000 %	54.011 / 17.781
Duración $\log(1 + x)$	0,241	0,968	99,258 %	53.954 / 17.838
Sin `loudness`	0,209	0,807	95,194 %	51.769 / 20.023

Cuadro 8: Sensibilidad de la partición K-Means. ARI y coincidencia se comparan con la solución base sobre las mismas canciones.

Los dos perfiles siguen siendo reconocibles en ambas variantes. Retirar `loudness` reduce la silueta y mueve más observaciones, señal de que esa variable contribuye a la separación. Los resultados no validan estabilidad frente a otras muestras, elecciones de K o métodos de agrupamiento.

7. Conclusiones y uso compartido

Ridge completo es la mejor de las variantes supervisadas evaluadas para el MAE de esta prueba aleatoria. La mejora depende marcadamente de géneros y persiste, con límites, cuando se apartan artistas principales. La regresión subestima sistemáticamente las canciones con popularidad al menos 70; por ello el ranking sirve como filtro exploratorio retrospectivo, no como sustituto del criterio humano. K-Means aporta un lenguaje descriptivo para explorar familias acústicas, pero sus grupos no son categorías rígidas ni predicen por sí mismos la popularidad.

Para el notebook integrador queda por medir si el ranking del 10 % cubre de forma distinta los dos perfiles K-Means. *Esta auditoría es una hipótesis, no un resultado.*

7.1. Traspaso a Ignacio y César

Como trabajo posterior, una evaluación temporal requeriría fechas válidas; extrapolar a Spotify exige una muestra con frecuencias naturales de géneros.

1. Reproducir el notebook 04a siguiendo `docs/ea2/lucas.md`; verificar la huella de la fuente, los 89.740 `track_id` únicos y la huella de la prueba común antes de comparar resultados.
2. Reutilizar las funciones del protocolo compartido y reservar la misma prueba aleatoria. Seleccionar hiperparámetros en validación propia; el diagnóstico agrupado exige una selección nueva dentro de esa partición.
3. Llevar al notebook 05 los resultados de las Tablas 3, 5, 6 y 8, con sus soportes y límites. Contrastar allí los enfoques de los tres integrantes antes de redactar una conclusión de equipo.
4. En la revisión cruzada, explicar por qué la señal de género puede estar amplificada por el muestreo, qué significa que todos los populares de prueba reciban predicción inferior a 70, cómo se calculó el lift y por qué la silueta 0,245 obliga a una interpretación prudente de los grupos.

Las figuras de modelamiento y clustering proceden del notebook 04a; las dos figuras de contexto proceden del EDA de EP1. El archivo principal de este informe es `docs/ea2/informe_lucas/main.tex` y el PDF compilado queda en esa misma carpeta. El código, notebook, imágenes y documento son archivos locales de la rama `feature/ea2-modeling-lucas` hasta que el equipo los integre. Así, la revisión puede hacerse sobre evidencia trazable sin confundir el informe individual con la entrega conjunta.