

Spotify Popularity Analysis

Informe técnico extendido y apoyo para defensa

Lucas Moncada Ignacio Silva César Rojas

11 de septiembre de 2026

Este documento complementa el README y los notebooks. Consolida evidencia, decisiones, limitaciones y argumentos para defensa; no sustituye los artefactos ejecutables ni constituye un modelo predictivo terminado.

Índice

1. Resumen ejecutivo	3
2. Introducción	4
3. Problema de negocio	4
4. Objetivos y KPIs	5
5. Fuente de datos	5
6. Metodología CRISP-DM	6
7. Comprensión inicial de los datos	7
8. Calidad y preparación de datos	9
8.1. Comparación antes y después	10
9. Análisis exploratorio profundo	10
9.1. Distribución procesada de popularidad	10
9.2. Pearson y Spearman	11
9.3. Matriz de correlación y redundancia	12
9.4. Relaciones bivariadas por cuantiles	12
9.5. Contenido explícito y tamaño de efecto	13
9.6. Géneros multietiqueta y sensibilidad	14
9.7. Valores extremos	15

10. Análisis de variables y utilidad para modelamiento	16
10.1. Cardinalidad de variables categóricas	17
10.2. Multicolinealidad y redundancia	17
11. Sesgos, ética y privacidad	17
11.1. Sesgo de muestreo	17
11.2. Sesgo temporal	17
11.3. Variables omitidas	18
11.4. Sesgo y memorización por artista	18
11.5. Sesgo por género y multietiqueta	18
11.6. Riesgos éticos	18
11.7. Privacidad	18
12. Limitaciones y matriz de riesgos técnicos	19
13. Recomendaciones para modelamiento e implicancias de negocio	20
13.1. Clasificación de variables	20
13.2. Implicancias de negocio	20
14. Preguntas probables de defensa y respuestas técnicas	21
15. Conclusiones	24

1 Resumen ejecutivo

Este proyecto estudia qué características musicales y contextuales están asociadas con la popularidad observada de canciones en Spotify. Su propósito es aportar evidencia para artistas, sellos, marketing, curadores y gestión de catálogo, sin presentar las asociaciones como causas ni como una receta de éxito. El trabajo sigue CRISP-DM y conserva trazabilidad mediante Git, notebooks ejecutables, funciones en Python, pruebas automatizadas y documentación de progreso.

La fuente entregada por la asignatura contiene 114.000 filas y 21 columnas. No representa 114.000 canciones diferentes: solo existen 89.741 valores únicos de `track_id`; 16.641 IDs aparecen más de una vez y generan 24.259 apariciones adicionales. Se detectaron tres celdas nulas, todas en una fila que además posee duración cero, y una columna técnica `Unnamed: 0` que reproduce el índice exportado. La distribución por género original contiene exactamente 1.000 filas para cada una de 114 etiquetas, indicio de un diseño de muestra balanceado y no de la prevalencia real del catálogo.

La preparación retiró la columna técnica y la única fila inválida. Después consolidó cada `track_id`, verificando que sus atributos musicales y textuales fueran invariantes. Las etiquetas de género se conservaron como una lista ordenada separada por barras verticales en `track_genres`; cuando un ID presentaba diferentes valores históricos de popularidad, se usó la mediana. El resultado contiene 89.740 canciones únicas, 20 columnas, cero nulos, cero IDs duplicados y duración estrictamente positiva.

Cuadro 1: Comparación reproducible del dataset antes y después de la preparación.

	Filas	Canciones unicas	Media	Mediana	Porcentaje igual a 0	Porcentaje mayor o igual a 70
dataset						
Original	114000	89741	33.239	35.000	14.053	4.800
Procesado	89740	89740	33.198	33.000	10.468	3.480

El EDA procesado obtiene una popularidad media de 33,20, mediana de 33 y desviación estándar de 20,58. El 10,47 % de las canciones tiene popularidad cero y el 3,48 % alcanza 70 o más. Ningún atributo acústico individual muestra una asociación fuerte con el objetivo. La mayor magnitud es `instrumentalness` (Pearson $-0,128$; Spearman $-0,124$); `loudness` y `danceability` presentan asociaciones positivas pequeñas. Entre predictores sí aparecen redundancias relevantes: `energy` con `loudness` (0,759) y con `acousticness` ($-0,733$).

Las canciones marcadas como explícitas tienen una media 4,03 puntos superior y una mediana cuatro puntos superior, pero el tamaño de efecto estandarizado es pequeño ($d = 0,196$). Esto distingue una diferencia visible en una muestra grande de una diferencia práctica considerable. El ranking por género es estable al exigir soportes mínimos de 100, 200 o 500 canciones, aunque esa estabilidad no corrige el muestreo artificialmente balanceado ni convierte las diferencias en efectos causales.

Los riesgos principales son la falta de temporalidad, variables contextuales omitidas, posible memorización de artistas, leakage mediante identificadores, alta cardinalidad y deriva del concepto de popularidad. Éticamente, un modelo podría reforzar ventajas existentes, reducir diversidad o automatizar promoción de forma injustificada. El dataset no contiene datos directos de oyentes, por lo que el riesgo de privacidad individual es relativamente bajo; aumentaría si se integraran perfiles, ubicaciones o historiales de escucha.

El proyecto está preparado para una etapa inicial de modelamiento de regresión. Se recomienda construir una línea base, excluir `track_id`, codificar géneros como multi-hot, evaluar con MAE, RMSE y R^2 , y documentar desempeño por segmentos. El resultado debe utilizarse como apoyo a

decisión humana, no como criterio único de mérito artístico, inversión o promoción.

2 Introducción

Las plataformas musicales generan metadatos y descriptores de audio que permiten caracterizar catálogos a una escala difícil de abordar manualmente. En este contexto, la inteligencia musical puede ayudar a describir segmentos, detectar patrones y priorizar preguntas de negocio. Sin embargo, la disponibilidad de atributos no implica que la popularidad pueda explicarse solo por la estructura sonora: la exposición, la promoción, la recencia y el reconocimiento previo también intervienen y no están observados en este dataset.

El proyecto analiza la relación entre atributos de canciones y **popularity**. Su alcance actual incluye comprensión del problema, evaluación de la fuente, preparación, EDA y recomendaciones para modelamiento. No incluye todavía un modelo entrenado ni una evaluación predictiva fuera de muestra.

Conviene distinguir tres conceptos:

- **Asociación:** dos variables cambian de forma relacionada en los datos observados. Pearson y Spearman cuantifican formas específicas de asociación.
- **Predicción:** un procedimiento estima valores para observaciones no usadas al ajustarlo. Requiere particiones y métricas fuera de muestra.
- **Causalidad:** un cambio deliberado en una variable produciría un cambio en otra. Exige un diseño causal, supuestos o evidencia que este estudio observacional no proporciona.

Por tanto, frases como “mayor sonoridad causa popularidad” o “la música explícita tiene éxito” no están respaldadas. El lenguaje correcto describe patrones de la muestra y formula hipótesis para validaciones futuras.

3 Problema de negocio

Artistas y organizaciones musicales deben decidir qué lanzamientos priorizar, cómo organizar un catálogo y dónde concentrar recursos promocionales sin conocer completamente el desempeño futuro. La pregunta central es:

¿Qué características musicales y contextuales están asociadas con la popularidad de una canción y cómo puede esta información apoyar decisiones de promoción y gestión de catálogo?

Los principales interesados y usos prudentes son:

- **Artistas:** comprender cómo se ubica una obra dentro de perfiles descriptivos, sin convertirlos en reglas creativas.
- **Sellos:** complementar revisión experta al priorizar experimentos o análisis de catálogo.
- **Marketing musical:** caracterizar segmentos y formular campañas que luego deben medirse.
- **Gestión de catálogo:** detectar grupos que requieren análisis específico y mantener una visión documentada de cobertura.
- **Curadores:** apoyar exploración de diversidad, nunca reemplazar juicio editorial.

Las restricciones son sustanciales: no hay fecha de extracción ni de lanzamiento, inversión, exposición en playlists, región o comportamiento de usuarios. La popularidad es histórica y dinámica según Spotify [4]. En consecuencia, el análisis puede orientar preguntas y priorizaciones, pero no garantizar desempeño comercial ni valorar mérito artístico.

4 Objetivos y KPIs

Objetivo general. Analizar relaciones entre atributos musicales y contextuales y la popularidad observada, dejando una base confiable y evidencia reproducible para evaluar modelos de regresión.

Objetivos específicos.

1. comprender el problema, los interesados y las decisiones relevantes;
2. documentar procedencia, estructura y calidad de la fuente;
3. preparar una unidad de análisis de una canción por `track_id`;
4. explorar distribuciones, relaciones, anomalías, redundancias y sesgos;
5. clasificar variables según utilidad y riesgo para modelamiento;
6. comunicar limitaciones éticas, de privacidad y de interpretación.

Cuadro 2: Indicadores del proyecto y su función.

Tipo	Indicador	Interpretación y uso
Negocio	Media y mediana de popularidad	Describen el centro del catálogo observado; no son metas de predicción por sí mismas.
Negocio	Proporción con popularidad ≥ 70	Segmento operativo de alta popularidad; el umbral no es una categoría oficial de Spotify.
Negocio	Popularidad por género	Compara segmentos con soporte; no estima prevalencia real ni efecto causal.
Calidad	Complejidad	Controla celdas disponibles y evita imputaciones injustificadas.
Calidad	Duplicidad de <code>track_id</code>	Verifica unidad de análisis y previene fuga entre entrenamiento y prueba.
Modelo	MAE	Error absoluto promedio en puntos de popularidad, interpretable en la escala original.
Modelo	RMSE	Penaliza más los errores grandes y complementa MAE.
Modelo	R^2	Proporción de variabilidad explicada respecto de una línea base; no mide causalidad.

Los KPIs de negocio describen utilidad potencial; las estadísticas descriptivas caracterizan la muestra; y las métricas técnicas solo serán válidas al evaluarse fuera de muestra.

5 Fuente de datos

El archivo operativo es `data/raw/Spotify_Tracks_Dataset.csv`, proporcionado por la asignatura y preservado sin modificaciones. Su estructura coincide con el conjunto publicado por Maharshi Pandya en Kaggle [3]. Esta coincidencia sustenta la descripción, pero la copia local y su trazabilidad son la fuente efectiva del análisis.

El CSV original tiene 114.000 filas y 21 columnas. Incluye identificadores, artista, álbum, nombre de pista, género, contenido explícito, duración y atributos acústicos. La variable objetivo `popularity` está en escala 0–100. La documentación de Spotify la relaciona principalmente con reproducciones y recencia, y el campo aparece actualmente como obsoleto en la API [4]. Se interpreta, por ello, como fotografía histórica y no como medición en tiempo real.

La integridad de la copia raw se controla mediante SHA-256:

b202fa49909b2d5cef71a04b1d21243cf36414535f2ca9272aa646721177bd

El diccionario completo está en docs/data_dictionary.md. En síntesis, los roles son:

Cuadro 3: Grupos de variables de la fuente.

Grupo	Variables representativas	Rol
Identificación	<code>track_id</code>	Trazabilidad; no predictor
Contexto	<code>artists</code> , <code>album_name</code> , <code>track_name</code> , género	Segmentación y posible alta cardinalidad
Audio	<code>danceability</code> , <code>energy</code> , <code>loudness</code> , <code>acousticness</code> , entre otras	Predictores candidatos
Estructura musical	<code>key</code> , <code>mode</code> , <code>tempo</code> , <code>time_signature</code>	Predictores categóricos o continuos según significado
Objetivo	<code>popularity</code>	Variable de respuesta histórica
Técnica	<code>Unnamed: 0</code>	Índice exportado, retirado

No se documenta la fecha exacta de extracción, la cobertura regional ni las condiciones completas de muestreo. Esas ausencias limitan actualización, generalización temporal y representatividad.

6 Metodología CRISP-DM

CRISP-DM organiza el trabajo en seis fases iterativas [1]. Un hallazgo de calidad, modelamiento o evaluación puede obligar a revisar una fase anterior; el flujo no es estrictamente lineal.

Cuadro 4: Estado de CRISP-DM en el proyecto.

Fase	Aplicación	Estado
Business Understanding	Problema, interesados, objetivos, KPIs y restricciones	Completada inicialmente
Data Understanding	Fuente, diccionario, calidad inicial y distribuciones	Completada inicialmente
Data Preparation	Índice, fila inválida, consolidación de IDs y géneros múltiples	Completada inicialmente
Modeling	Líneas base y regresiones justificadas	Pendiente
Evaluation	MAE, RMSE, R^2 , utilidad, errores por grupos y robustez temporal	Pendiente
Deployment	Repositorio reproducible, informe y presentación	En construcción

La separación entre notebooks refleja responsabilidades: `01_data_understanding.ipynb` documenta negocio y diagnóstico; `02_data_preparation.ipynb` transforma la fuente;

03_exploratory_analysis.ipynb estudia canciones únicas. La lógica común se implementa en `src/spotify_popularity/` y se verifica en `tests/`.

7 Comprensión inicial de los datos

La inspección original confirmó 114.000 filas, 21 columnas, cero filas exactamente duplicadas y 89.741 IDs únicos. Hay 16.641 IDs repetidos que abarcan 40.900 filas; equivalen a 24.259 apariciones adicionales. En consecuencia, una fila representa una asignación pista-género y no necesariamente una canción nueva.

Las tres celdas nulas corresponden a artista, álbum y nombre de una única fila. Esa misma fila tiene duración cero. El bajo porcentaje de nulos no basta para concluir alta calidad: duplicidad semántica, unidad de análisis y consistencia son más relevantes en este caso.




Figura 1: Distribución inicial de popularidad sobre 114.000 asignaciones pista-género. La media es 33,24 y la mediana 35; el gráfico todavía pondera varias veces canciones multigénero.

La Figura 1 permite diagnosticar concentración baja-media, pero no debe interpretarse aún como distribución por canción única. El 14,05 % de las filas vale cero y el 4,80 % alcanza 70 o más.




Figura 2: Duración original limitada al percentil 99 para preservar legibilidad. El máximo no se elimina y alcanza aproximadamente 87,29 minutos.

La Figura 2 separa visualización de decisión: recortar el eje no elimina observaciones. La mediana original es 3,55 minutos y el percentil 99 es 8,85; la fila con duración cero requiere tratamiento por combinar múltiples problemas de calidad.




Figura 3: Conteo inicial de contenido explícito. Solo 8,55% de las filas está marcado como explícito; **False** no debe interpretarse más allá de la definición disponible.




Figura 4: Distribuciones iniciales de atributos acústicos. **speechiness**, **instrumentalness** y **liveness** concentran masa cerca de cero.

La Figura 4 anticipa asimetría y acumulaciones válidas en variables acotadas; por ello media, IQR y gráficos deben interpretarse con sus formas distributivas. Finalmente, las 114 etiquetas de género tienen exactamente 1.000 filas cada una: esto facilita comparaciones con soporte, pero es evidencia de balance artificial y no de prevalencia real.

8 Calidad y preparación de datos

La preparación se ejecuta desde la fuente inmutable mediante `scripts/build_processed_dataset.py`. La implementación en `src/spotify_popularity/data/preparation.py` valida esquema, detecta filas inválidas, comprueba atributos invariantes y consolida IDs.

Cuadro 5: Problemas, decisiones y riesgos residuales de preparación.

Problema	Evidencia	Decisión	Justificación	Riesgo residual
Índice exportado	Secuencia <code>Unnamed: 0</code>	Retirar del derivado	No describe una canción y podría introducir orden artificial	Ninguno relevante
Fila inválida	Tres textos nulos y duración cero	Excluir una fila	No hay evidencia para imputar identidad ni duración	Posible pérdida mínima de cobertura
IDs repetidos	16.641 IDs; 24.259 apariciones extra	Consolidar por <code>track_id</code>	Evita doble conteo y fuga entre particiones	La popularidad histórica se resume
Géneros múltiples	Una pista puede aparecer en varias etiquetas	Unir etiquetas únicas con <code> </code>	Conserva información sin duplicar canciones	Requiere encoding multietiqueta
Popularidad variable	720 IDs repetidos difieren en el objetivo	Usar mediana	Es determinista y robusta sin privilegiar el orden del archivo	No representa actualidad ni trayectoria

Elegir la primera fila habría vinculado el resultado al orden del CSV; promediar sería más sensible a discrepancias extremas; eliminar todos los IDs repetidos descartaría información válida. La mediana y la preservación de etiquetas equilibran trazabilidad, robustez y retención de datos. El código se detiene si atributos declarados invariantes entran en conflicto, evitando consolidaciones silenciosas.

El contrato posterior confirma 89.740 filas y 20 columnas, 89.740 IDs únicos, cero celdas nulas, cero duraciones no positivas y géneros no vacíos. Estas comprobaciones validan la entrada al EDA, pero no eliminan sesgos de origen ni garantizan representatividad.

8.1 Comparación antes y después

Cuadro 6: Impacto cuantitativo de consolidar `track_id`. Tabla generada por `scripts/build_latex_tables.py`.

dataset	Filas	Canciones unicas	Media	Mediana	Porcentaje igual a 0	Porcentaje mayor o igual a 70
Original	114000	89741	33.239	35.000	14.053	4.800
Procesado	89740	89740	33.198	33.000	10.468	3.480

La tabla 6 muestra que las canciones únicas pasan de 89.741 a 89.740 por la exclusión de la fila inválida, mientras las filas caen 21,28 %. La media apenas cambia (33,24 a 33,20), pero la mediana baja de 35 a 33, la masa en cero de 14,05 % a 10,47 % y el segmento de 70 o más de 4,80 % a 3,48 %. Esto demuestra que la duplicación por género modificaba la ponderación de la distribución: incluso si la media permanece cercana, otras características relevantes cambian.

9 Análisis exploratorio profundo

El EDA se realiza sobre una fila por canción. Este cambio hace que cada estadística responda a la unidad de negocio elegida y no a la cantidad de etiquetas de género asociadas.

9.1 Distribución procesada de popularidad

La media es 33,198, la mediana 33, la desviación estándar 20,578, los percentiles 25 y 75 son 19 y 49, y el percentil 95 es 67. El rango completo 0–100 es compatible con la escala documentada.




Figura 5: Popularidad de 89.740 canciones únicas. La concentración baja-media y la masa en cero son relevantes para líneas base y evaluación por segmentos.

La Figura 5 importa porque define la dificultad del objetivo y advierte que una métrica global puede ocultar errores distintos en canciones de baja y alta popularidad. Los valores 0 y 100 no son errores solo por estar en los extremos. La limitación es que la distribución describe una captura histórica sin fecha de referencia.

9.2 Pearson y Spearman

Pearson resume covariación lineal; Spearman calcula asociación monotónica sobre rangos y es menos dependiente de una relación lineal exacta. La comparación evita concluir a partir de una sola forma.

Cuadro 7: Correlaciones con **popularity**, ordenadas por magnitud de Spearman.

	Pearson	Spearman
variable		
instrumentalness	-0.127	-0.124
loudness	0.072	0.067
speechiness	-0.047	-0.067
danceability	0.064	0.055
energy	0.014	-0.016
duration_ms	-0.023	0.013
liveness	-0.014	-0.012
valence	-0.012	-0.011
acousticness	-0.039	0.010
tempo	0.007	0.008

Todas las magnitudes son pequeñas. **instrumentalness** es la señal negativa más visible; **loudness** y **danceability** son positivas débiles. Diferencias de signo entre métodos, como en **acousticness** y **duration_ms**, sugieren formas no lineales, empates o patrones segmentados. La implicancia

es evaluar modelos multivariantes sin esperar gran poder explicativo de un atributo aislado. La limitación central es que correlación no controla confusores ni implica causalidad.

9.3 Matriz de correlación y redundancia




Figura 6: Matriz de Pearson para variables numéricas. Las celdas más intensas aparecen entre predictores de audio, no con el objetivo.

La Figura 6 permite detectar redundancia: **energy**–**loudness** alcanza 0,759; **energy**–**acousticness**, –0,733; y **loudness**–**acousticness**, –0,583. Para regresión lineal, coeficientes asociados pueden volverse inestables y difíciles de interpretar. Esto no obliga a retirar variables: permite planificar regularización y diagnóstico. La matriz solo refleja relaciones pares y lineales.

9.4 Relaciones bivariadas por cuantiles

Un scatterplot con casi 90 mil puntos produciría sobreposición. Se dividen valores en cuantiles y se representa la mediana de popularidad de cada intervalo, manteniendo todos los datos en el cálculo.




Figura 7: Popularidad mediana por cuantiles de cinco atributos. Las curvas permiten observar forma y no solo un coeficiente global.

La Figura 7 muestra caída más consistente con **instrumentalness**; **loudness** y **danceability** crecen en parte del rango, pero no de forma ilimitada. **energy** y **acousticness** exhiben curvatura. Esto respalda términos no lineales o modelos flexibles como hipótesis de modelamiento, no reglas creativas. Los cuantiles resumen heterogeneidad y pueden ocultar subgrupos por género o época.

9.5 Contenido explícito y tamaño de efecto




Figura 8: Distribución de popularidad por clasificación explícita. El solapamiento entre grupos es amplio pese a diferencias en los centros.

El grupo no explícito contiene 82.036 canciones y el explícito 7.704. Sus medias son 32,852 y 36,884; las medianas, 33 y 37. Para medir relevancia práctica se calculó d de Cohen con desviación estándar combinada [2].

Cuadro 8: Diferencias y tamaño de efecto de **explicit**.

	Valor
Canciones no explicitas	82036.000
Canciones explicitas	7704.000
Diferencia de medias	4.032
Diferencia de medianas	4.000
d de Cohen	0.196

La diferencia de 4,03 puntos puede resultar estadísticamente detectable con una muestra grande, pero $d = 0,196$ indica separación estandarizada pequeña. La Figura 8 confirma fuerte solapamiento. La asociación puede depender de género, público, recencia y promoción; no prueba que hacer una canción explícita aumente popularidad.

9.6 Géneros multietiqueta y sensibilidad

Cada valor de **track_genres** se divide por 1. Una canción puede participar en varias etiquetas: las filas expandidas no constituyen canciones adicionales. El resumen cuenta IDs únicos por etiqueta y exige soporte para evitar líderes de muestras mínimas.




Figura 9: Géneros con mayor mediana de popularidad entre etiquetas con al menos 100 canciones.

Cuadro 9: Sensibilidad del líder por mediana a distintos soportes mínimos.

	Generos incluidos	Genero lider	Mediana lider
Soporte minimo			
100	114	pop	66.000
200	114	pop	66.000
500	114	pop	66.000

Los 114 géneros superan 100, 200 y 500 canciones, y **pop** mantiene mediana 66. Esto demuestra estabilidad frente a esos umbrales en esta muestra, no superioridad universal. La Figura 9 sirve para segmentar el dataset; su limitación es el balance artificial del origen y la superposición de canciones entre etiquetas.

9.7 Valores extremos

El criterio IQR marca observaciones fuera de $[Q_1 - 1,5IQR, Q_3 + 1,5IQR]$. Es una regla de identificación, no una prueba de error.

Cuadro 10: Rangos y recuentos fuera de IQR.

variable	Minimo	P1	P99	Maximo	Fuera de IQR
duration_ms	8586.000	61871.850	546010.980	5237295.000	4225
tempo	0.000	65.165	193.652	243.372	514
loudness	-49.531	-28.542	-1.628	4.532	5026
speechiness	0.000	0.025	0.619	0.965	10644
instrumentalness	0.000	0.000	0.958	1.000	19613
liveness	0.000	0.041	0.950	1.000	6981




Figura 10: Revisión de extremos. Las colas largas y acumulaciones en cero requieren interpretación por variable, no eliminación automática.

duration_ms alcanza 5.237.295 ms (87,29 minutos); puede representar contenido largo válido. **tempo** incluye cero y merece validación puntual, pero no se infiere que sea inválido sin metadatos adicionales. **loudness** llega a $-49,531$ y $4,532$ dB. En **speechiness**, **instrumentalness** y **liveness**, una gran cantidad fuera de IQR es compatible con distribuciones asimétricas acotadas 0–1. La implicancia es probar transformaciones o escaladores robustos y analizar sensibilidad; eliminar puntos podría borrar géneros completos o casos legítimos.

10 Análisis de variables y utilidad para modelamiento

La tabla siguiente integra descripción estadística, relación observada y decisión técnica. Una correlación débil no implica inutilidad multivariable: interacciones y relaciones no lineales pueden aportar información, pero deben comprobarse fuera de muestra.

Cuadro 11: Síntesis de variables para la siguiente etapa.

Variable	Descripción estadística	Relación con popularidad	Utilidad o riesgo
danceability	Continua 0–1, distribución amplia	Pearson 0,064; Spearman 0,055; curva por cuantiles	Candidata; permitir no linealidad
energy	Continua 0–1	Asociación casi nula con target	Candidata, pero redundante con sonoridad y acousticness
loudness	dB con cola negativa	Pearson 0,072; Spearman 0,067	Candidata; escalar y revisar extremos
speechiness	Masa cerca de cero y cola alta	Pearson -0,047; Spearman -0,067	Candidata; posible transformación y segmentación
acousticness	Continua 0–1, relación no lineal	Pearson -0,039; Spearman 0,010	Candidata con cautela por redundancia
instrumentalness	Acumulación en cero y valores altos	Mayor asociación: -0,128/-0,124	Candidata; no convertir asociación en regla
liveness	Asimétrica y acotada	Cerca de cero	Mantener para prueba multivariable
valence	Distribución amplia 0–1	Cerca de cero	Candidata; relacionada con danceability
tempo	Continua; incluye cero y máximo 243,372	Cerca de cero	Validar extremos y escalar
duration_ms	Cola larga; máximo 87,29 minutos	Pearson -0,023; Spearman 0,013	Evaluar $\log_{1p}$ y escala robusta
explicit	7.704 verdaderas de 89.740	Diferencia media 4,03; $d = 0,196$	Binaria candidata; auditar por confusores
track_genres	114 etiquetas básicas; combinaciones multi-etiqueta	Diferencias descriptivas por género	Multi-hot; evitar doble conteo

10.1 Cardinalidad de variables categóricas

Cuadro 12: Cardinalidad sobre el dataset procesado.

variable	Valores unicos	Porcentaje sobre filas	Riesgo
artists	31437	35.031	Alta cardinalidad y memorizacion
album_name	46589	51.916	Alta cardinalidad y memorizacion
track_name	73608	82.024	Alta cardinalidad y texto libre
track_genres	1432	1.596	Multietiqueta; combinaciones de etiquetas
explicit	2	0.002	Desbalance y posibles variables de confusion
key	12	0.013	Categoría nominal codificada como numero
mode	2	0.002	Baja cardinalidad
time_signature	5	0.006	Categoría discreta con clases poco frecuentes

artists, **album_name** y **track_name** podrían memorizar identidades o ejemplos concretos. El dato de 1.432 valores únicos de **track_genres** cuenta combinaciones de etiquetas, no géneros básicos. **key**, **mode** y **time_signature** están almacenadas como números, pero su significado es categórico; tratarlas como distancias continuas impondría relaciones arbitrarias.

10.2 Multicolinealidad y redundancia

La multicolinealidad ocurre cuando predictores aportan información lineal muy similar. No afecta necesariamente la predicción global, pero puede aumentar la varianza de coeficientes, cambiar signos y dificultar explicaciones. Aquí, **energy**, **loudness** y **acousticness** forman el principal grupo de atención.

El escalamiento coloca variables en rangos comparables y es necesario para penalizaciones, aunque no elimina correlación. Ridge puede estabilizar coeficientes distribuyendo señal entre predictores; Lasso puede seleccionar, pero su elección entre variables correlacionadas puede ser inestable. El factor de inflación de varianza (VIF) sería útil si se adopta una regresión lineal explicativa; no se calcula ahora porque aún no se definió la matriz final de diseño ni el propósito inferencial.

11 Sesgos, ética y privacidad

11.1 Sesgo de muestreo

La fuente contiene exactamente 1.000 filas por cada uno de 114 géneros. Este balance facilita comparaciones, pero no representa la prevalencia natural de canciones ni de reproducciones en Spotify. Además, las canciones multigénero aparecen repetidas en el origen, por lo que estadísticas agregadas ponderan más a pistas con varias etiquetas. La consolidación corrige el doble conteo por canción, pero no reconstruye un muestreo aleatorio del catálogo completo.

11.2 Sesgo temporal

popularity depende de reproducciones y recencia [4]. Al faltar fecha de extracción y lanzamiento, no es posible distinguir canciones nuevas en crecimiento de clásicos estables ni evaluar evolución. Un modelo entrenado en esta fotografía puede sufrir *concept drift*: la relación entre atributos y popularidad cambia con tendencias, reglas de plataforma y audiencias.

11.3 Variables omitidas

No se observan inversión de marketing, exposición en playlists, viralidad, popularidad previa del artista, colaboraciones, región, fecha de lanzamiento, estacionalidad ni exposición externa. Estas variables podrían explicar simultáneamente atributos y popularidad, de modo que las correlaciones de audio no deben interpretarse como efectos. Su ausencia también fija un techo razonable a la capacidad predictiva.

11.4 Sesgo y memorización por artista

Hay 31.437 valores de **artists**. Una partición aleatoria puede dejar canciones del mismo artista en entrenamiento y prueba; el modelo reconocerá reputación histórica y aparentará generalizar mejor de lo que lo haría con artistas nuevos. Para estimar ese escenario se necesita validación agrupada por artista o una evaluación separada de artistas no vistos.

11.5 Sesgo por género y multietiqueta

Una canción puede contribuir a varias etiquetas en análisis expandidos. Comparar géneros como grupos excluyentes sería incorrecto, y un multi-hot puede aprender asociaciones del diseño de muestreo. Las métricas por género deben informar soporte, permitir pertenencia múltiple y evitar concluir que una etiqueta determina el desempeño.

11.6 Riesgos éticos

Una predicción puede reforzar artistas ya populares, favorecer estilos dominantes, reducir oportunidades de artistas nuevos y homogeneizar decisiones creativas. También puede confundirse probabilidad estimada con mérito artístico o usarse como regla automática de inversión. Una correlación como la de **instrumentalness** no autoriza recomendar eliminar elementos instrumentales: refleja esta muestra y puede estar mediada por géneros y exposición.

Principios de uso responsable:

- usar el modelo como apoyo a decisión humana y documentar su propósito;
- comunicar incertidumbre, datos de entrenamiento y límites de generalización;
- revisar errores y cobertura por género, condición explícita y artistas vistos/no vistos;
- monitorear deriva y recalibrar solo con datos trazables;
- evitar asignaciones automáticas de presupuesto o promoción de alto impacto;
- preservar diversidad creativa y habilitar revisión de decisiones.

11.7 Privacidad

El dataset contiene metadatos de canciones, nombres públicos de artistas y atributos musicales. No incluye directamente identidad, ubicación, perfiles ni historial de escucha de oyentes; el riesgo de privacidad individual es relativamente bajo frente a datos conductuales. Aun así, se mantiene trazabilidad, minimización y respeto por las condiciones de uso de la fuente.

Si una etapa futura integra usuarios, playlists personales, ubicaciones o eventos de escucha, cambia materialmente el riesgo. Serían necesarios propósito y base legal definidos, minimización, controles de acceso, retención limitada, agregación o seudonimización, revisión de reidentificación y una evaluación de impacto antes del uso.

12 Limitaciones y matriz de riesgos técnicos

Las principales limitaciones son: captura histórica sin fecha, objetivo dinámico e imperfecto, muestra balanceada artificialmente, variables contextuales ausentes, análisis observacional sin causalidad y falta de una evaluación fuera de muestra. También se desconoce si el conjunto cubre de forma homogénea regiones, periodos, idiomas y niveles de exposición.

Cuadro 13: Matriz de riesgos ajustada a la evidencia disponible.

Riesgo	Impacto	Probabilidad	Mitigación
Leakage o memorización por <code>track_id</code>	Alto	Alta si se incluye	Excluir del diseño; conservar para trazabilidad
Memorización por artista	Alto	Alta	Comparar partición aleatoria con grupos por artista; controlar encoding
Deriva temporal	Alto	Alta	Obtener fechas, validar temporalmente y monitorear desempeño
Muestra no representativa	Alto	Alta	Limitar generalización; documentar cobertura y reponderar solo con marco válido
Variables omitidas	Alto	Alta	Incorporar contexto trazable; no interpretar causalmente
Multicolinealidad de audio	Medio	Alta	Escalar, regularizar y diagnosticar coeficientes
Géneros multietiqueta	Medio	Alta	Multi-hot, soporte explícito y métricas no excluyentes
Extremos válidos confundidos con errores	Medio	Media	Validación puntual y análisis de sensibilidad
Desempeño desigual por segmentos	Alto	Media	Evaluar errores por género, explicit y artistas vistos/no vistos
Sobreconfianza de negocio	Alto	Media	Revisión humana, documentación y límites de uso

Probabilidad e impacto son evaluaciones cualitativas para priorizar controles, no frecuencias estimadas. Deben revisarse cuando existan particiones, modelo, datos temporales y contexto de uso concreto.

13 Recomendaciones para modelamiento e implicancias de negocio

13.1 Clasificación de variables

Cuadro 14: Tratamiento recomendado antes de entrenar.

Clasificación	Variables	Recomendación
Target	popularity	Regresión; conservar escala 0–100 y analizar masa en cero
Recomendadas	Atributos acústicos, explicit	Línea base y modelos regularizados; escalar cuando corresponda
Transformación	duration_ms , extremos continuos	Comparar original con log1p ; usar pipeline para evitar fuga
Encoding	track_genres , key , mode , time_signature	Multi-hot para géneros; one-hot o codificación categórica para el resto
Alta cardinalidad	artists , album_name , track_name	Excluir de línea base; evaluar después con validación estricta y propósito claro
Excluir	track_id	Nunca predictor; usar solo como identificador y control

El pipeline debe ajustar transformaciones solo con entrenamiento. Una línea base que prediga la mediana permite comprobar si modelos más complejos agregan valor. Después, una regresión lineal o Ridge ofrece interpretabilidad; alternativas no lineales pueden explorar curvaturas observadas, sin tuning excesivo en esta fase.

La partición aleatoria es un punto de partida, pero debe complementarse con grupos por artista para medir generalización a identidades nuevas. Si se obtienen fechas, una partición temporal es más realista para predecir periodos posteriores. La unicidad actual de **track_id** evita una fuga directa, aunque no la dependencia entre canciones del mismo artista.

MAE se interpreta como error medio en puntos; RMSE revela errores grandes; R^2 compara contra la media y puede ser bajo o negativo fuera de muestra. Deben presentarse intervalos mediante validación cruzada y métricas por segmentos. Un R^2 alto no demuestra causalidad, equidad ni utilidad operativa.

13.2 Implicancias de negocio

El análisis enseña que la popularidad no se explica mediante una regla acústica simple. Algunas variables contienen señal descriptiva y los géneros segmentan diferencias, pero factores de exposición probablemente faltan. Una futura estimación podría priorizar revisión humana, comparar segmentos o identificar casos donde convenga investigar contexto adicional.

No puede afirmarse que cambiar energía, sonoridad, explicitud o instrumentalidad produzca éxito. La predicción debería acompañarse de información de incertidumbre y nunca determinar por sí sola presupuesto, lanzamiento o mérito artístico. La decisión útil combina evidencia cuantitativa, objetivos creativos, conocimiento del mercado y experimentación posterior.

14 Preguntas probables de defensa y respuestas técnicas

¿Por qué 114.000 filas no son 114.000 canciones?

Respuesta corta. Porque solo hay 89.741 `track_id` únicos en el origen.

Explicación técnica. Una canción puede aparecer en varias filas por sus asignaciones de género. Hay 16.641 IDs repetidos y 24.259 apariciones adicionales.

Error que evitar. Llamar “duplicados exactos” a esas filas: contienen distintos géneros y no son idénticas.

¿Por qué consolidaron `track_id`?

Respuesta corta. Para usar una canción como unidad y evitar doble conteo y fuga.

Explicación técnica. Si el mismo ID llega a entrenamiento y prueba, el desempeño queda inflado. La consolidación mantiene atributos invariantes y reúne etiquetas.

Error que evitar. Eliminar todos los tracks repetidos y perder canciones válidas.

¿Por qué utilizaron la mediana de popularidad?

Respuesta corta. Era una regla robusta, determinista y no dependía del orden de filas.

Explicación técnica. En 720 IDs repetidos el objetivo difería. Elegir el primero sería arbitrario y la mediana reduce influencia de discrepancias extremas.

Error que evitar. Decir que la mediana recupera la popularidad “verdadera” o actual.

¿Qué es una correlación?

Respuesta corta. Una medida de asociación entre variables.

Explicación técnica. Resume dirección e intensidad bajo una definición concreta; aquí se usan asociaciones lineales y monotónicas. Sus valores van de -1 a 1 .

Error que evitar. Interpretar un valor bajo como ausencia total de cualquier relación.

¿Qué diferencia existe entre Pearson y Spearman?

Respuesta corta. Pearson mide asociación lineal; Spearman, asociación monotónica por rangos.

Explicación técnica. Spearman tolera mejor curvaturas monotónicas y reduce sensibilidad a magnitudes extremas, aunque ambos pueden fallar ante relaciones complejas.

Error que evitar. Afirmar que Spearman demuestra causalidad o resuelve todos los outliers.

¿Por qué correlación no implica causalidad?

Respuesta corta. Porque una asociación puede surgir por confusores, selección o causalidad inversa.

Explicación técnica. No hay intervención, temporalidad ni control suficiente de marketing, género, recencia y exposición.

Error que evitar. Convertir un coeficiente en una recomendación para modificar la música.

¿Por qué `instrumentalness` no significa que una canción será impopular?

Respuesta corta. Su correlación es débil y describe promedios de esta muestra.

Explicación técnica. Pearson es $-0,128$ y Spearman $-0,124$; existe amplio solapamiento y posibles diferencias por género y exposición.

Error que evitar. Tratar una tendencia poblacional débil como destino de una canción.

¿Qué significa multicolinealidad?

Respuesta corta. Que varios predictores contienen información lineal redundante.

Explicación técnica. `energy` correlaciona $0,759$ con `loudness` y $-0,733$ con `acousticness`. En modelos lineales puede desestabilizar coeficientes.

Error que evitar. Suponer que siempre obliga a eliminar una variable o que impide predecir.

¿Por qué no eliminaron outliers?

Respuesta corta. Un extremo estadístico no es automáticamente un error.

Explicación técnica. Canciones largas, habladas, instrumentales o en vivo pueden ser casos válidos. IQR se utilizó para revisar, y la fila inequívocamente inválida sí se retiró.

Error que evitar. Aplicar una regla IQR sin considerar el significado de la variable.

¿Qué problema tiene usar `artists` como predictor?

Respuesta corta. Puede memorizar reputación y no generalizar a artistas nuevos.

Explicación técnica. Hay 31.437 valores únicos y un mismo artista puede aparecer en ambos conjuntos. Se necesita control de encoding y validación agrupada.

Error que evitar. Presentar reconocimiento de identidades como aprendizaje musical general.

¿Qué problema tiene usar `track_id`?

Respuesta corta. Es un identificador, no una característica generalizable.

Explicación técnica. Tiene un valor por canción procesada; un modelo puede memorizar y no aprender un patrón reutilizable. Se conserva para trazabilidad y particiones.

Error que evitar. Codificarlo numéricamente o con one-hot como predictor.

¿Cómo funciona `track_genres`?

Respuesta corta. Contiene etiquetas únicas separadas por `|`.

Explicación técnica. Al consolidar un track se preservan todos sus géneros ordenados. Para analizar se expande; para modelar se crean indicadores por etiqueta.

Error que evitar. Contar las filas expandidas como canciones nuevas.

¿Qué es multi-hot encoding?

Respuesta corta. Una columna binaria por etiqueta, permitiendo varias activas por fila.

Explicación técnica. Una canción pop|rock tendrá 1 en ambas columnas. A diferencia de one-hot exclusivo, respeta pertenencia múltiple.

Error que evitar. Elegir solo el primer género y descartar información.

¿Qué sesgos tiene el dataset?

Respuesta corta. Muestreo balanceado por género, temporalidad desconocida, variables omitidas y dependencia por artista.

Explicación técnica. Estos sesgos afectan agregados, generalización temporal y evaluación de artistas nuevos. La consolidación corrige duplicación, no representatividad.

Error que evitar. Afirmar que 1.000 filas por género reflejan el catálogo real.

¿Qué riesgos éticos existen?

Respuesta corta. Reforzar popularidad previa, reducir diversidad y automatizar promoción.

Explicación técnica. Un sistema optimizado con señales históricas puede reproducir desigualdades de exposición y convertir correlaciones en criterios normativos.

Error que evitar. Equiparar popularidad estimada con calidad o mérito artístico.

¿Qué privacidad hay que considerar?

Respuesta corta. El riesgo actual es bajo porque no hay datos de oyentes, pero no es cero.

Explicación técnica. Existen metadatos públicos de obras y artistas; se exige trazabilidad y uso responsable. Integrar perfiles o escuchas requeriría controles adicionales.

Error que evitar. Concluir que todo dato musical puede reutilizarse sin condiciones.

¿Por qué popularity es problemática?

Respuesta corta. Es dinámica, histórica y depende de factores no observados.

Explicación técnica. Reproducciones y recencia influyen, no se conoce la fecha de extracción y Spotify marca el campo como obsoleto en la API actual.

Error que evitar. Tratarla como una medida atemporal de éxito o calidad.

¿Qué harían distinto con datos temporales?

Respuesta corta. Definirían un horizonte y validarían entrenando en pasado y probando en futuro.

Explicación técnica. Se crearían variables disponibles al momento de predicción, evitando información posterior, y se mediría deriva entre periodos.

Error que evitar. Mezclar fechas aleatoriamente y afirmar capacidad prospectiva.

¿Por qué usar MAE, RMSE y R^2 ?

Respuesta corta. Miden aspectos complementarios del error.

Explicación técnica. MAE es interpretable en puntos; RMSE enfatiza errores grandes; R^2 compara variabilidad explicada contra una referencia. Deben calcularse fuera de muestra.

Error que evitar. Elegir una sola métrica o interpretar R^2 como porcentaje de aciertos.

¿La diferencia de `explicit` es importante?

Respuesta corta. Es visible, pero pequeña en escala estandarizada.

Explicación técnica. La media difiere 4,03 puntos y d de Cohen es 0,196. Con muestras grandes puede existir significancia estadística sin gran relevancia práctica.

Error que evitar. Recomendar contenido explícito basándose en una comparación no causal.

¿Por qué las correlaciones débiles no descartan un modelo?

Respuesta corta. Un modelo puede combinar señales, interacciones y curvaturas.

Explicación técnica. Las correlaciones son pares y resumen formas simples; el valor real debe medirse fuera de muestra contra una línea base.

Error que evitar. Prometer que complejidad garantiza buen desempeño.

15 Conclusiones

El proyecto dispone de una cadena reproducible desde una fuente raw preservada hasta un dataset analítico de 89.740 canciones únicas. La preparación resolvió la anomalía con nulos y duración cero, retiró el índice exportado, consolidó IDs y conservó géneros múltiples. Los controles posteriores confirman el contrato esperado y las pruebas automatizadas protegen la lógica central.

El EDA demuestra que la popularidad se concentra en valores bajos y medios y que las asociaciones acústicas individuales son débiles. `instrumentalness` ofrece la señal de mayor magnitud, pero no determina el resultado. La redundancia entre energía, sonoridad y `acousticness` debe considerarse en modelos lineales. Las diferencias por explicitud y género son descriptivas, presentan solapamiento o sesgos de cobertura y no justifican afirmaciones causales.

La robustez adicional confirma que el efecto estandarizado de `explicit` es pequeño, que el ranking principal de géneros no cambia entre soportes de 100, 200 y 500, y que artistas, álbumes y nombres tienen cardinalidad suficiente para introducir memorización. Los extremos se mantienen porque no existe evidencia general de error; se proponen transformaciones y validación de sensibilidad.

Los límites más importantes son temporalidad desconocida, muestra no representativa, objetivo dinámico y variables contextuales omitidas. Estos límites acotan tanto la capacidad predictiva como la interpretación de negocio. Éticamente, una futura herramienta debe apoyar revisión humana, explicitar incertidumbre y evitar automatizar asignaciones de alto impacto.

La siguiente etapa debe establecer una línea base de regresión, aplicar pipelines sin leakage, codificar categorías según su semántica y comparar particiones aleatorias, agrupadas por artista y, si se obtienen fechas, temporales. El éxito no consiste solo en reducir error global: requiere generalización defendible, desempeño por segmentos, utilidad real y uso responsable.

Referencias

- [1] Pete Chapman, Julian Clinton, Randy Kerber, Thomas Khabaza, Thomas Reinartz, Colin Shearer, and Rüdiger Wirth. Crisp-dm 1.0: Step-by-step data mining guide. Technical report, SPSS, 2000.
- [2] Jacob Cohen. *Statistical Power Analysis for the Behavioral Sciences*. Lawrence Erlbaum Associates, 2 edition, 1988.
- [3] Maharshi Pandya. Spotify tracks dataset. Kaggle, <https://www.kaggle.com/datasets/maharshipandya/-spotify-tracks-dataset>, s. f. Estructura coincidente con el archivo proporcionado por la asignatura.
- [4] Spotify for Developers. Web api reference: Get track. <https://developer.spotify.com/documentation/web-api/reference/get-track>, s. f. Definición y estado del atributo de popularidad consultados por el proyecto.